

Predicción de diagnóstico de cáncer

Estudio de viabilidad mediante Machine Learning y Redes Neuronales

50.001

Pacientes analizados

5

Modelos comparados (4 ML + MLP)

0,5748

F1 del modelo ganador

1

Objetivo del proyecto y datos disponibles

Estudio de viabilidad: ¿pueden los datos del hospital anticipar un diagnóstico de cáncer?

El hospital recoge datos multimodales de 50.001 pacientes y necesita evaluar si son suficientes para anticipar un diagnóstico de cáncer mediante modelos de IA. Variable objetivo: cáncer (0/1).

50.001

Pacientes

19,29%

Prevalencia cancer

4,18:1


Ratio desbalance

Las 6 colecciones disponibles (unidas por paciente_id):

Coleccion	Contenido	# vars
01 BIOQUIMICOS	Marcadores en sangre (glucosa, hemoglobina, leucocitos...)	7
02 CLINICOS	Comorbilidades + variable objetivo cancer	7
03 GENETICOS	Mutaciones oncologicas (BRCA1, TP53, KRAS, EGFR...)	7
03 ECONOMICOS	Coste y uso del sistema (⚠ data leakage)	5
05 GENERALES	Habitos de vida (fumador, alcohol, actividad fisica)	4
06 SOCIODEMOGRAFICOS	Edad, nivel educativo, zona, estado civil	7

Selección de features con justificación empírica

30 INCLUIDAS · 7 EXCLUIDAS · 1 TARGET



⚠ EXCLUIDAS: 5 por data leakage (coste_total, dias_hospital, coste_farmaco, num_ingresos, vive) · alcohol (varianza 0) · paciente_id

2


Resultados de los modelos ML clasicos

Cuatro modelos entrenados sobre 32.000 muestras y evaluados sobre 10.001 de test

Comparativa de los 4 modelos (umbral 0,50) — con feature engineering

#	Modelo	F1 ★	AUC-ROC	Precision	Recall
1	RandomForest	0,5719	0,8367	0,4990	0,6698
2	HistGradientBoosting	0,5527	0,8409	0,4365	0,7532
3	LogisticRegression	0,5526	0,8417	0,4343	0,7595
4	XGBoost	0,5423	0,8221	0,4890	0,6086

Matriz de confusion · RandomForest (test)




Validación contra modelo generativo del metadata

Spearman ρ = 0,862


entre el ranking aprendido (sin feature engineering) y los pesos generativos REALES declarados en el metadata oficial.

⇒ El modelo aprende los predictores CORRECTOS. Tras anadir n_mutaciones y n_comorbilidades, esta se convierte en la feature #1 mas importante (sustituye al atajo aprendido).

Curvas ROC y Precision-Recall (test)




Top 5 features aprendidas (RF + XGBoost)



3 Red Neuronal Multicapa (MLP) – núcleo técnico

Arquitectura ≈ 46.913 parametros · regularización estricta · threshold tuning sin data leakage

Arquitectura: Dense(240) → Dense(120) → Dense(60) → Dense(1)




45.961
Parametros


17
Epocas (EarlyStop)

21 S
Tiempo (CPU)

Curvas de entrenamiento por epoca



Threshold tuning sobre VALIDACION (sin data leakage)



Resultado final (test) · MLP vs mejor ML



Modelo / config	F1 ★	AUC-ROC	Precision	Recall
MLP umbral 0,50	0,5521	0,8418	0,4282	0,7766
MLP umbral 0,63 (GANADOR)	0,5748	0,8418	0,5305	0,6273
RandomForest (mejor ML)	0,5719	0,8367	0,4990	0,6698

Hallazgo: la red neuronal gana
Con threshold tuning sobre validacion (umbral=0,63), el MLP supera a los 4 modelos ML clasicos en F1.

4 Comparativa global: 4 ML vs Red Neuronal MLP

Bar chart, curvas ROC y Precision-Recall superpuestas, ranking final


Comparativa de los 5 modelos · 4 métricas



Ranking final · ordenado por F1 (metrica principal)

#	Modelo	F1 ★	AUC-ROC	Precision	Recall
1	MLP umbral 0,63 (PyTorch)	0,5748	0,8418	0,5305	0,6273
2	RandomForest (+ feat eng)	0,5719	0,8367	0,4990	0,6698
3	HistGradientBoosting	0,5527	0,8409	0,4365	0,7532
4	LogisticRegression	0,5526	0,8417	0,4343	0,7595
5	XGBoost	0,5423	0,8221	0,4890	0,6086

Trade-off Precision–Recall



0,5748

F1 SCORE — MLP umbral 0,63 (PyTorch)

63 %

RECALL — 1.210 de 1.929 casos

0,84

AUC-ROC — discriminacion global

VIABLE COMO SISTEMA DE CRIBADO · Filtro inicial de priorización, no diagnóstico definitivo



LIMITACIONES DEL SISTEMA ACTUAL

Dataset sintético

Logistica + ruido $N(0; 0,8)$. Sociodemograficas sin senal real.

Sin datos longitudinales ni imágenes

Falta evolucion temporal, mamografias, TC y patologia.

Calibración sobre-confiada

class_weight sesga las probabilidades. Aplicar Platt scaling.

Coste FP vs FN no parametrizado

En oncologia, un FN suele costar mucho mas que un FP.



DATOS ADICIONALES QUE MEJORARÍAN EL MODELO

Marcadores tumorales

CA-125 (ovario), CEA (colorrectal), PSA (prostata), AFP, HE4.

Imagenologia

Mamografia digital, TC torax/abdomen, RM hepatica.

Datos longitudinales

Evolucion temporal de bioquimicos (12-24 meses).

Historial familiar y exposición ambiental

1er grado, ocupacion (amianto, radon, radiacion).



Conclusiones finales del estudio

Cuatro hallazgos clave que avalan el rigor metodológico del trabajo



0,5748

F1 SCORE DEL GANADOR (MLP)

Sistema de cribado viable

El MLP en PyTorch supera a los 4 modelos ML clásicos. Detecta el 63 % de los pacientes con cáncer entre los 10.001 de test, con 53 % de precisión.



0,84

AUC-ROC GLOBAL

La red neuronal supera a los árboles

Tras threshold tuning sobre validación (umbral=0,63), el MLP queda 1º en F1 por delante de RandomForest (0,5719). Los 5 modelos comparten AUC $\approx$ 0,84.



0,862

SPEARMAN ρ

Pipeline validado contra el modelo generativo

Correlación entre el ranking aprendido y los pesos verdaderos del metadata oficial. El modelo aprende los predictores correctos.



SEED=42

REPRODUCIBILIDAD ESTRICTA

Sin data leakage en ninguna fase

Threshold tuning sobre validación. Test intacto hasta el final. Scaler ajustado solo en train. `cuda.deterministic = True` en PyTorch.