

Prediccion de diagnostico de cancer

Estudio de viabilidad mediante Machine Learning y Redes Neuronales

50.001

Pacientes analizados

5

Modelos comparados (4 ML + MLP)

0,5719

F1 del modelo ganador

1

Objetivo del proyecto y datos disponibles

Estudio de viabilidad: ¿pueden los datos del hospital anticipar un diagnóstico de cáncer?

El hospital recoge datos multimodales de 50.001 pacientes y necesita evaluar si son suficientes para anticipar un diagnostico de cancer mediante modelos de IA. Variable objetivo: cancer (0/1).

50.001

Pacientes

19,29%

Prevalencia cancer

4,18:1


Ratio desbalance

Las 6 colecciones disponibles (unidas por paciente_id):

Coleccion	Contenido	# vars
01 BIOQUIMICOS	Marcadores en sangre (glucosa, hemoglobina, leucocitos...)	7
02 CLINICOS	Comorbilidades + variable objetivo cancer	7
03 GENETICOS	Mutaciones oncologicas (BRCA1, TP53, KRAS, EGFR...)	7
03 ECONOMICOS	Coste y uso del sistema (⚠ data leakage)	5
05 GENERALES	Habitos de vida (fumador, alcohol, actividad fisica)	4
06 SOCIODEMOGRAFICOS	Edad, nivel educativo, zona, estado civil	7

Seleccion de features con justificacion empirica

30 INCLUIDAS · 7 EXCLUIDAS · 1 TARGET



⚠ EXCLUIDAS: 5 por data leakage (coste_total, dias_hospital, coste_farmaco, num_ingresos, vive) · alcohol (varianza 0) · paciente_id

2


Resultados de los modelos ML clasicos

Cuatro modelos entrenados sobre 32.000 muestras y evaluados sobre 10.001 de test

Comparativa de los 4 modelos (umbral 0,50) — con feature engineering

#	Modelo	F1 ★	AUC-ROC	Precision	Recall
1	RandomForest	0,5719	0,8367	0,4990	0,6698
2	HistGradientBoosting	0,5527	0,8409	0,4365	0,7532
3	LogisticRegression	0,5526	0,8417	0,4343	0,7595
4	XGBoost	0,5423	0,8221	0,4890	0,6086

Matriz de confusion • RandomForest (test)




Validacion contra modelo generativo del metadata

Spearman ρ = 0,862


entre el ranking aprendido (sin feature engineering) y los pesos generativos REALES declarados en el metadata oficial.

⇒ El modelo aprende los predictores CORRECTOS. Tras anadir n_mutaciones y n_comorbilidades, esta se convierte en la feature #1 mas importante (sustituye al atajo aprendido).

Curvas ROC y Precision-Recall (test)




Top 5 features aprendidas (RF + XGBoost)



3 Red Neuronal Multicapa (MLP) — nucleo tecnico

Arquitectura ≈ 46.913 parametros · regularizacion estricta · threshold tuning sin data leakage

Arquitectura: Dense(240) → Dense(120) → Dense(60) → Dense(1)




46.801
Parametros


31
Epocas (EarlyStop)

42 s
Tiempo (CPU)

Curvas de entrenamiento por epoca



Threshold tuning sobre VALIDACION (sin data leakage)



Resultado final (test) · MLP vs mejor ML

Modelo / config	F1 ★	AUC-ROC	Precision	Recall
MLP umbral 0,50	0,5413	0,8337	0,4182	0,7672
MLP umbral 0,64 (optimo)	0,5615	0,8337	0,5138	0,6190
RandomForest (GANADOR)	0,5719	0,8367	0,4990	0,6698

Hallazgo metodologico



El feature engineering (n_mutaciones, n_comorbilidades) ayuda a los arboles pero no al MLP. RandomForest gana.

4

Comparativa global: 4 ML vs Red Neuronal MLP

Bar chart, curvas ROC y Precision-Recall superpuestas, ranking final


Comparativa de los 5 modelos • 4 metricas



Ranking final • ordenado por F1 (metrica principal)

#	Modelo	F1 ★	AUC-ROC	Precision	Recall
1	RandomForest (+ feat eng)	0,5719	0,8367	0,4990	0,6698
2	MLP (umbral 0,69)	0,5615	0,8337	0,5138	0,6190
3	HistGradientBoosting	0,5527	0,8409	0,4365	0,7532
4	LogisticRegression	0,5526	0,8417	0,4343	0,7595
5	XGBoost	0,5423	0,8221	0,4890	0,6086

Trade-off Precision-Recall



0,5719

F1 SCORE — RandomForest + feat eng

67 %

RECALL — 1.292 de 1.929 casos

0,84

AUC-ROC — discriminacion global

VIABLE COMO SISTEMA DE CRIBADO • Filtro inicial de priorizacion, no diagnostico definitivo



LIMITACIONES DEL SISTEMA ACTUAL

Dataset sintetico

Logistica + ruido $N(0; 0,8)$. Sociodemograficas sin senal real.

Sin datos longitudinales ni imagenes

Falta evolucion temporal, mamografias, TC y patologia.

Calibracion sobre-confiada

class_weight sesga las probabilidades. Aplicar Platt scaling.

Coste FP vs FN no parametrizado

En oncologia, un FN suele costar mucho mas que un FP.



DATOS ADICIONALES QUE MEJORARIAN EL MODELO

Marcadores tumorales

CA-125 (ovario), CEA (colorrectal), PSA (prostata), AFP, HE4.

Imagenologia

Mamografia digital, TC torax/abdomen, RM hepatica.

Datos longitudinales

Evolucion temporal de bioquimicos (12-24 meses).

Historial familiar y exposicion ambiental

1er grado, ocupacion (amianto, radon, radiacion).



Conclusiones finales del estudio

Cuatro hallazgos clave que avalan el rigor metodológico del trabajo



0,84

AUC-ROC

Sistema de cribado viable

Detecta el 67 % de los pacientes con cancer entre los 10.001 de test. Suficiente como filtro inicial de priorizacion clinica.



+0,008

F1 EN RF • -0,015 EN MLP

Feature engineering no es universal

n_mutaciones y n_comorbilidades ayudan a los arboles pero perjudican al MLP. Hallazgo metodologico defendible.



0,862

SPEARMAN ρ

Pipeline validado contra el modelo generativo

Correlacion entre el ranking aprendido y los pesos verdaderos del metadata oficial. El modelo aprende los predictores correctos.



SEED=42

REPRODUCIBILIDAD Estricta

Sin data leakage en ninguna fase

Threshold tuning sobre validacion. Test intacto hasta el final. Scaler ajustado solo en train. Seeds fijos en todas las fases.